

基于数字图像处理及神经网络的车牌定位识别

董阴晴, 葛俊康, 韦众河

(电子科技大学 信息与通信工程学院, 成都 611731)

【摘要】 本文完整地完成了车牌识别的三个流程：定位、分割、识别，实现了较为可靠的车牌识别功能。针对不同的情况，本文综合运用了HSV色彩空间、边缘检测以及Faster-RCNN神经网络等工具，实现了对车牌的定位。经过实验，对于预先给定的165张测试图片，本文均可以实现正确地车牌定位，定位准确率100%。通过竖直投影，倒序分割的方法，本文可以对165张图片中的大部分图片进行字符分割。本文利用两个卷积神经网络CNN完成对字符的识别。经实验，CNN单个数字或字母的识别准确率为99.57%，汉字的识别准确率为96.22%。综合分割识别两个过程，165张测试图片中有4张本文无法正确地分割识别。分割识别准确率97.57%。整个车牌定位识别处理过程的准确率为97.57%

关键词： HSV色彩空间 边缘检测 错切变换 卷积神经网络CNN Faster-RCNN

License plate location and recognition based on digital image processing and neural network

DONG Yinqing, GE Junkang, Wei Zhonghe

(College of Information and Communication Engineering, University of Electronic Science and Technology of China, Chengdu 611731)

Abstract: This paper has fully completed LPR three processes: positioning, segmentation, and achieved a plate recognition function reliably. In view of different situations, HSV color space, edge detection and Faster- RCNN neural network and other tools were comprehensively used to locate license plates. Through the experiment, it already achieved that locating correctly license plate positioning for all the 165 test pictures given in advance. Positioning accuracy rate is 100%. By means of vertical projection and reverse order segmentation, it can perform character segmentation on most of the 165 test pictures. In this paper, two convolutional neural network CNN complete the identification of the characters. According to the experiments, the recognition accuracy of single digits or letters of CNN is 99.57%, and that of Chinese characters is 96.22%. Combined with the two process of segmentation and recognition, 4 of 165 test images cannot be correctly segmented or recognized in this paper. The segmentation and recognition accuracy rate is 97.57%. The accuracy of the entire LPR process is 97.57%

Keywords : HSV color space, edge detection, shearing

1 图片预处理

1.1 光照均衡

车牌图像采集过程中,由于场景的光照不均匀,可能导致一些重要的车牌信息无法凸显甚至被掩盖掉,需要进行光照均衡。基于二维伽马函数光照不均匀图像自适应校正算法利用多尺度高斯函数去除场景的光照分量,然后构造了一种二维伽马函数,并利用光照分量的分布特性调整二维伽马函数的参数,降低光照过强区域的亮度值,提高光照过暗区域图像的亮度值,最终实现对光照不均匀图像的自适应校正处理^[1]。

1.2 去噪声处理

图像在获取和传输过程中,都可能会收到各种噪声的影响,导致图片质量恶化。本文采用的高斯滤波是一种线性平滑滤波,能够有效的抑制噪声,平滑图像,广泛应用于图像处理中。

2 车牌定位

2.1 基于 HSV 色彩空间的车牌定位

该方法适用于对非蓝色车辆进行车牌定位。HSV 颜色空间有三个分量,分别是 H (色调)、S (饱和度)、V (亮度)^[2]。

通过先验知识,汽车车牌的 HSV 值可由下表确定:

表 2-1 HSV 的取值范围

	蓝色	黄色	白色	黑色
色调	200~255 度	25~55 度	\	\
饱和度	0.4~1	0.4~1	0~0.1	\
亮度	0.3~1	0.3~1	0.9~1	0~0.35

“\”表示不予考虑的项目

实现步骤如下:

(1) 将 RGB 图像转化为 HSV 图像,计算各行中蓝色像素数目,找出蓝色像素最多的行标 B_rmax,以 B_rmax 为基础分别向上向下寻找仍然存在蓝色像素的行,进而确定蓝色区域的行边界。

(2) 计算各列中蓝色像素数目,找出蓝色像素最多的列标 B_cmax,再从左右两侧向 B_cmax 扫描各列的蓝色像素,找到仍有蓝色像素的列,进而确定蓝色区域的列边界。

(3) 由行列边界实现了对车牌的粗定位。经过实验发现对于非蓝色车身且背景中无其他大面积蓝色区域的图片可以有效的定位出车牌的位置。

2.2 基于边缘检测的车牌定位

对于无法单靠颜色这一指标定位车牌的蓝色车辆,基于边缘检测的车牌定位方法是一种可行的办法。

2.2.1 图像灰度化

将 RGB 图像转化为灰度图像,方便下一步处理,处理过程更加简便和省时^[3]。

2.2.2 边缘检测

为了使得图像的边缘、轮廓及图像的细节变得更加清晰,在灰度化后,还需要采用边缘检测的方法^[4]。本文采用的 Prewitt 算子是利用特定区域内像素灰度值产生的差分实现边缘检测。Prewitt 算子在水平和垂直方向上的检测结果比 Robert 算子更加明显,适合用来检测灰度渐变的图像。边缘图像如图 2-1



图 2-1 边缘图像

2.2.3 形态学处理

为了将车牌区域从整体图像中分离出来以方便后续处理, 需要利用形态学处理来提取区域。数学形态学的算法具有天然的并行实现的结构, 实现了形态学分析和处理算法的并行, 大大提高了图像分析和处理的速度^[5]。

在对图像进行边缘检测后, 利用形态学的腐蚀、闭合两个基本运算的组合得到图像中的连通域, 然后使用 `bwareaopen` 函数移除不符合车牌特征的小对象, 进而定位出车牌。形态学处理后图如图 2-2



图 2-2 形态学处理结果

2.2.4 综合特征判定:

通过形态学处理出来的图像, 往往不止一个连通区域。对于每一个连通区域我们都要进行利用车牌的综合特征进行判定。

颜色特征: 由先验知识, 在整个车牌中蓝色背景像素占整个车牌的 70%。将 RGB 图像转化为 HSV 颜色模型, 统计每个候选车牌的蓝色像素点数量, 当蓝色像素点数量大于设定阈值时, 该候选区域判断为车牌区域。该方法不能确定唯一的车牌区域, 容易受环境影响。

长宽比判断: 车牌的标准尺寸为 440mmx140mm, 标准长高比约为 3.1, 通过把候选车牌区域标记成一个方形, 计算方形的长和宽, 通过设定一定的长宽比阈值, 再次筛选候选车牌区域。当侧面拍摄

车牌时候, 长宽比会发生一定程度的变化, 阈值需适当放宽。

面积特征: 车牌在整张图片中所占的像素面积, 具有一定的规律性, 小组实验后发现车牌像素上限 600000 个, 下限 10000 个。

纹理特征: 车牌区域的字符目标有一定的规律性: 牌照内多个字符基本成水平排列, 形成一个矩形区域。对于二值化后的图像进行垂直投影, 得到的垂直投影图具有连续的峰-谷-峰的特点。在垂直投影图一定高度范围内, 做一条平行于 x 轴的直线, 在该直线上统计连续白色像素点区域的个数 n , 若满足条件: $6 \leq n \leq 15$, 则认为该车牌候选区域是真的车牌区域, 否则认为该候选区域为假的^[6]。

2.2.5 基于 Faster-RCNN 定位

对于传统方法定位失效的情况, 本文提出了利用 Faster-RCNN 网络进行车牌的方法。

2.2.5.1 Faster-RCNN 基本原理

Faster-RCNN 建立在卷积神经网络 CNN 的基础之上。关于 CNN 的相关原理的说明会在下文中展开。

由于 CNN 的识别性能优异, 越来越多的人将 CNN 应用到了目标检测上来。Faster-RCNN 是 Ross B. Girshick 于 2016 年在 Fast-RCNN 的基础之上提出的。其克服了后者检测耗时长的缺点, 将候选区域生成、分类检测集成在同一个网络之中, 实现了端

到端的训练其主要结构如图 2-3 所示^[7]




图 2-3 Faster-RCNN 网络结构

Faster-RCNN 的结构主要分为三大部分，第一部分是共享卷积层 Backbone 用于生成共享特征图；第二部分是候选区域生成网络 RPN；第三部分是对候选区域进行分类的网络 Classifier，如图。其中 RPN 的工作原理如下

2.2.5.1.1 RPN 主要功能及原理

RPN 网络通过在共享特征图上滑动的窗口为每一个像素点生成多种面积和长宽比为预定值的目标框，称之为 anchor，其数量取决于预先设定的面积和长宽比的数量。然后利用 Softmax 层判断 anchor 是前景还是背景，即判断 anchor 是否覆盖目标。接着 RPN 利用 bboxreg 层对判定为前景的 anchor 进行坐标修正。边框修正主要 t_x, t_y, t_w, t_h 由 4 个值完成。坐标修正公式为：

$$\begin{aligned} x' &= x + t_x & y' &= y + t_y \\ w' &= w \cdot t_w & h' &= h \cdot t_h \end{aligned}$$

t_x, t_y, t_w, t_h 通过训练时采用 SmoothL1Loss 方法训练得到。

2.2.5.1.2 Classifier 主要功能

RPN 生成的 Proposals 与共享特征图一同被送入 RoI Pooling。RoI Pooling 是一种特殊的池化层用于从共享特征图中取 ROI(region of interest)即 Proposals 的特征，并送入全连接层。随后 RPN 利用 Softmax 层用于判断 ROI 具体为哪一类别的事物，利用 bboxreg 用于对 anchor 坐标的第二次修正，修正原理与上文中提及的原理一致。

综上有整个 Faster-RCNN 处理图片的流程如下图：




图 2-4 本文数据集采样

2.2.5.2 本文的实现方法

本方法的核心思想是将车牌定位问题转化为目标检测问题，将一副图片分为车牌和背景两部分，然后通过 Faster-RCNN 进行分类预测，最终输出一个包含图片中的车牌的矩形框。

2.2.5.2.1 数据集

本文中从互联网上的同类型 demo 所使

用的数据集以及中科大车牌识别数据集 CCPD 中挑选了不同角度、不同距离、各种环境下的车辆拍摄图片共 300 张, 部分数据集如图 2-5。通过 MATLAB 自带的 ImageLabeler 程序对图像进行标注。

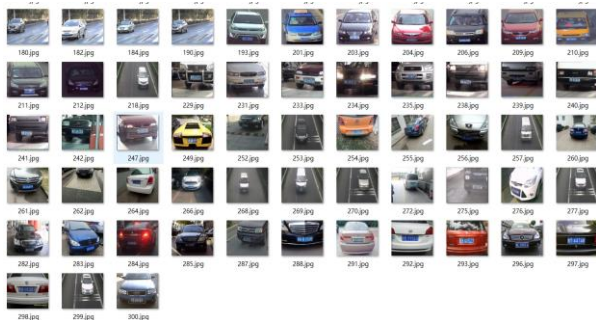


图 2-5 本文数据集采样

2.2.5.2.2 网络结构

本文在 MATLAB Deep learning toolbox 中自带的 resnet50 网络的基础之上搭建了一个共 188 层的 Faster-RCNN 网络。其中 RPN 与 Classifier 的结构分别如下图 2-6 和图 2-7;




图 2-6 本文中的 RPN 模块




图 2-7 本文中的 Classifier 模块

网络的输入尺寸为 $480 \times 640 \times 3$ 。预定的 anchor 的 6 种大小为 $[25, 61; 50, 122; 100, 244;$

$200, 488; 400, 976; 800, 1952]$, 比例约为 1: 2 由 MATLAB 根据图片标注结果自动生成。

2.2.5.2.3 训练参数

由于整个训练时间较为耗时, 本文先将 learning rate 设置为 10^{-3} , maxEpochs 设置为 300 经行训练, 再将以上两参数分别设置为 10^{-4} 和 100 再进行训练, 训练时的 MiniBatchSize 为 3。训练时采取采用 RPN 与 Fast-RCNN 交替训练的方式, 并将与标签的 IoU(Intersection over union)大于 0.6 的 anchor 判定为前景(positive); 小于 0.3 的 anchor 判定为背景(negative), 其余的不使用。

2.2.5.2.4 利用网络进行定位

利用 Faster-RCNN 网络对车牌进行定位的具体流程如下:

- ① 首先将图片大小修改为网络输入大小即 $480 \times 640 \times 3$ 。
- ② 利用 MATLAB 自带的 detect 函数, 调用 Faster-RCNN 网络进行车牌定位, 返回一个 1×4 的向量 $bbox$ 其四个值的含义分别为矩形框的列坐标、行坐标、宽度、高度]
- ③ 将获得的矩形框 $bbox$ 映射回原图片。假设 $bbox'$ 为映射结果; $k_x = 640/col$; $k_y = 480/row$; 则:

$$bbox' = \begin{bmatrix} k_x & 0 & 0 & 0 \\ 0 & k_y & 0 & 0 \\ 0 & 0 & k_x & 0 \\ 0 & 0 & 0 & k_y \end{bmatrix}^{-1} bbox$$

其中 col 为原图像的列数、 row 为原图像的行数。

- ④ 根据 $bbox'$ 将车牌从原图像中提取出来, 得到车牌图片。

2.2.5.2.5 定位效果如图 2-8



图 2-8 Faster-RCNN 定位效果图

2.2.5.2.6 本方法的优缺点

优点: ①本方法将车牌定位问题转化为目标检测问题。通过神经网络提取图片特征, 生成候选目标区域, 本方法有效地避免了图片背景颜色、光线明暗程度等因素对定位效果的影响, 进而实现对传统方法难以定位的图片进行正确的车牌定位。②同时本方法采用 Faster-RCNN 网络对图片进行处理, 相较于 RCNN 与 Fast-RCNN 具有更快的速度 (约 2s)。③本方法不受限于车牌的颜色, 还可以对新能源车牌进行定位, 如图 2-9 所示。当前新能源汽车的逐渐普及, 本方法具有一定的现实意义。



图 2-9 Faster-RCNN 定位新能源车牌效果图

缺点: ①本方法只能实现对车牌的粗略定位, 无法实现 100%准确的车牌定位, 需要与传统的方法相结合的使用。②本方法可能会出现截取不到完整车牌的情况, 这与 anchor 预定大小、训练时前景 IoU 阈值等众多因素有关, 直接优化网络的输出结果难度较大。③虽然本方法识别速度较快, 但由于网络规模较大, 因此加载网络所需的时间也较长 (约 30s)。

2.2.6 定位流程

综上所述, 本文完整的车牌定位流程如图 2-10

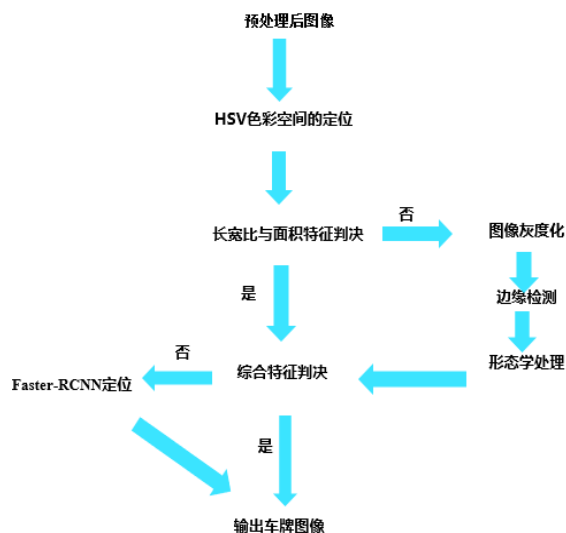


图 2-10 完整定位流程图

3 车牌校正

车牌校正分为车牌旋转、再次定位和错切变换三部分

3.1 基于 Radon 变换的车牌旋转

由于拍摄角度的问题, 定位出来的图片在多数情况下是倾斜的, 需要进行旋转变换保证上下边框水平。本文采用基于 Radon 变换的车牌旋转处理^[8]。步骤如下:

1. 对于选取出来的图片, 转化为灰度图后, 去除离散噪点。2. 利用边缘检测, 对图像中水平线进行强化处理。3. 计算图像的 Radon 变换, 获取倾斜角度。4. 根据倾斜角度, 对图像进行倾斜校正。旋转效果图 3-1



图 3-1 Radon 变换旋转效果图

3.2 再次定位

对于旋转过后的车牌区域再次使用基于 HSV 色彩空间的定位方法去除车牌以外的部分, 到达精确定位的目的。

3.3 基于垂直投影的错切变换

3.3.1 基本原理

基于垂直投影的错切变换是通过字符间的相对间隙的宽度来确定车牌二值图像的垂直倾斜角度。基本思想: 倾斜字符间的相对间隔小于垂直字符间的相对间隔。利用不同的角度对车牌图像进行错切变换处理。把处理后, 字符间相对间隔最大的图像当作矫正后的正确图像。

对于已经除去边框车牌的二值图像, 字符间的总间隔等于其垂直投影向量中元素 0 的个数。对于未去除边框的车牌, 选取特定的阈值, 其字符间的总间隔为垂直投影向量中小于给定阈值的元素个数。由于车牌图像长度确定, 当字符间的总间隔最大时, 垂

直投影向量中大于给定阈值的元素个数最少。

3.3.2 实现步骤概述

(1) 用不同的错切角度 θ , 对于精确定位的车牌进行错切, 对每种情况的图片求垂直投影向量 W

(2) 为了避免车牌上下边框带来的影响, 选取向量 W 里最小值 U , 设定判决阈值为 T , 则 T 需满足 T 略大于 U , 测试表明 T 的值在 13 附近。提取 W 里所有大于 T 的元素成新的向量 S 。

(3) 记录每次投影过后, 向量 S 的维度, 找到最小维度对应的错切角度就是作为最终的错切角度 θ_s 对精确定位后的图像进行错切变换。错切变换的校验矩阵如下:

$$\begin{bmatrix} X' & Y' & 1 \end{bmatrix} = \begin{bmatrix} X & Y & 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & 0 \\ \tan \theta_s & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

其中 X 、 Y 分别为车牌二值图像的横纵坐标矩阵 X' 、 Y' 分别为校正后的车牌二值图像的横纵坐标矩阵。

3.3.3 错切效果图

车牌原图和错切效果图分别为图 3-2, 图 3-3



图 3-2 车牌图像



图 3-3 错切效果图

4 车牌分割

4.1 去除车牌字符周围的边框

定位操作从原图片中选取出来图像在经过二值化处理后,除了车牌字符以外,还包括车牌本身具有的金属边框,铆钉等会对接下来字符切割与字符识别切割不利的因素(如图4-1)。因此在分割之前必须去调车牌的上下边框。



图 4-1 去边框之前

4.1.1 基本原理

本文通过统计每一行的跳变次数来判断车牌图片中边框和铆钉的位置。若某行穿过字符,则相较于穿过铆钉或金属边框的行,从黑色到白色或从白色到黑色的跳变次数更多。

4.1.2 实现方法概述

本文利用 MATLAB 自带的 `diff` 与 `sum` 命令求得各行的跳变次数,从中间开始向上下两侧扫描,若某一行的跳变次数小于 10 则结束循环。

4.1.3 去边框的效果如图 4-2



图 4-2 去边框

4.2 车牌分割

4.2.1 基本原理

本文通过竖直投影倒序分割这一传统方法对车牌进行分割。由于车牌之间留有很大的空隙。因此通过界定字符之间的空隙就可以实现对字符的分割。而通过比较各列与预先设定的阈值之间的大小,将小于阈值的列判定为空隙,就可以完成空隙的界定。

4.2.2 阈值选取

在实际操作中,由于水平或竖直边框没有完全去除,可能会造成字符的断裂或粘连,以及将竖直边框误判为字符的问题。为此本文采取以一种较为简单的自适应阈值的方法。针对第一个问题,本文将车牌按列等分为四个区间,分别对这四个区间的竖直投影值进行排序,并从排序后的序列中取出第 20 个元素,之后再对从每个区间中取出的值求均值,将该均值作为界定空隙的阈值。针对第二个问题,本文从各列的竖直投影值中取最大的 8 个元素并求和。将该和作为字符判定阈值。若分割后的“字符”的像素点数小于字符判定阈值则判定该“字符”为干扰,丢弃之。

4.2.3 实现方法概述

分割算法具体流程如下:

- ① 设数组 one_col 为各列竖直投影值的集合,阈值为 $thresh$, 字符阈值为 $threshChar$, 字符计数器 $j = 0$
- ② 设定字符预期宽度 $w = 50$
- ③ 将界定字符的两个指针 $tail$ 和 $head$ 初始化为图片的列数。
- ④ 若 $one_col(tail) \leq thresh$ 则 $tail = tail - 1$, 否则结束循环且令 $head = tail$ 。
- ⑤ 若 $one_col(head) > thresh$ 则 $head = head - 1$, 否则结束循环
- ⑥ 若 $(tail - head + 1) < w$, 则适当改变 $tail$ 和 $head$ 的值,直到 $(tail - head + 1) \geq w$, 但在这个过程中需保证 $one_col(head) \leq thresh$ 且 $one_col(tail + 1) \leq thresh$ 以免粘连到其他字符。
- ⑦ 若 $\sum_{head}^{tail} one_col(i) > threshChar$ 则 $j = j + 1$

- ⑧ $tail = head$ 。若 $j < 7$ 则跳转到步骤④，否则结束程序。

4.2.4 分割效果如图 4-3




图 4-3 分割

5 基于 CNN 的字符识别

5.1 卷积神经网络基本原理

2012 年, Alex Krizhevsky 凭借卷积神经网络 (Convolutional Neural Networks, CNN) 赢得了 ImageNet 挑战赛冠军。而 CNN 在分类识别上的出色表现也使其成为了图像识别领域的研究热点。卷积神经网络的结构一般包括输入层、卷积层、激活层、池化层、全连接层和最后的输出层构成, 图 5-1。




图 5-1 卷积神经网络结构

CNN 可以直接对二维图像进行处理, 从而有效地保留了原图像的特征。通过卷积核在图片上滑动, 池化层下采样, CNN 可以在有效的提取图像特征同时, 防止过拟合, 从而避免了人工提取特征的弊端, 极大的提高了分类识别的正确率。卷积层、池化层提取特征的过程如下^[9]:

设 CNN 输入的原始图像为 P ; x_j^l 表示第 l 层卷积层的第 j 个特征图则; $f()$ 表示激活函数; M_j^{l-1} 表示 $l-1$ 层的输出集合; k_{ij}^l

表示卷积核; b_j^l 表示卷积特征图 x_j^l 的加性偏置; $*$ 表示卷积运算, 则:

$$x_j^l = f(\sum_{i \in M_j^{l-1}} x_i^{l-1} * k_{ij}^l + b_j^l)$$

假设 M_j^{l-1} 的大小为 $[m_{l-1}, n_{l-1}, c_{l-1}]$, 卷积核大小为 $[x_l, y_l, c_{l-1}]$, 数目为 c_l , 则 M_j^l 的大小为 $[m_{l-1} - x_l + 1, n_{l-1} - y_l + 1, c_l]$ 。

池化层使用最大值或平均值操作对卷积层提取到的特征图进行降维, 计算过程如下:

$$x_j^l = f(\beta_j^l \text{down}(x_j^{l-1}) + b_j^l)$$

$\text{down}()$ 表示下采样函数; β 表示下采样系数; b 是偏置。

最后, 全连接层将卷积层和池化层提取的特征图映射为一特征向量传递给 SoftMax 分类器进行分类。整个 CNN 处理图像的流程如图 5-2 所示




图 5-2 CNN 处理图像流程

5.2 本文的实现方法

本文利用 MATLAB 自带的 Deep learning toolbox 搭建了两个卷积神经网络分别用于识别车牌中的数字字母与汉字。用于训练的数据集来自互联网以及部分从训练车牌上分割来的字符。

识别汉字的卷积神经网络共有 15 层。输入图像大小为 28x28。特征提取层由三个卷积层及附属的正则化层、池化层、激活函数层组成。其中各个卷积层的激活函数均采

用 ReLU。最后一层卷积层不进行池化操作，保留全部特征送入全连接层。三个卷积层与两个池化层的具体信息如表 5-1 以及表 5-2。

表 5-1 三个卷积层卷积核参数

	Conv1	Conv2	Conv3
Size	5x5x1	5x5x16	5x5x32
Number	16	32	64
Stride	[1, 1]	[1, 1]	[1, 1]
Padding	Same	Same	[0 0 0 0]

表 5-2 两个池化层的参数

	Pool1	Pool2
Type	Max_pooling	Max_pooling
Size	2x2	2x2
Stride	[2, 2]	[2, 2]

识别汉字的卷积神经网络的输出层由 SoftMax 层和 Classification 层组成。由于全国共有 31 个省（区、市）。故 SoftMax 层有 31 个输出，分别为输入图像分别为其中某一类的概率。最终汉字的识别正确率达到 96.22%。

识别数字和字母的卷积神经网络与识别汉字的网络结构相同。唯一的区别在于 SoftMax 层有 34 个输出。这是因为牌的数字和字母一共有 34 种。最终单个数字和字母的识别正确率为 99.57%。

最终的识别效果如图 5-3



图 5-3 最终识别效果

6 总结

本文提出了一种基于数字图像处理和神经网络的车牌定位识别方法，实现了从预处理开始到字符识别结束的整个图片

处理流程。

本文创新性的提出了 HSV 色彩空间定位+边缘检测定位+Faster-RCNN 网络定位的综合定位方法，适合各种复杂环境下的车牌定位，测试图片定位正确率 100%。

在车牌校正过程中，本文创新性采用基于垂直投影的错切变换，在未去除车牌边框的情况下实现对车牌的垂直错切校正

分割识别处理上，本文采用基于垂直投影的车牌分割方案和基于 CNN 网络字符识别方案，CNN 单个数字或字母的识别准确率为 99.57%，汉字的识别准确率为 96.22%。

对于测试的 165 张图片，整个系统的综合正确率达到了 97.57%。本方法准确率高，适应性强，能够满足实际车牌自动识别的应用需求。

参考文献：

- [1] 刘志成, 王殿伟, 刘颖, 等. 基于二维伽马函数的光照不均匀图像自适应校正算法[J]. 北京理工大学学报, 2016, 36(2):191-196.
- [2] 陈海霞, 崔茜. 复杂背景下基于颜色的车牌定位方法研究[J]. 现代电子技术, 2016, 39(23):52-54.
- [3] 孙正. 数字图像处理与识别[M]. 北京: 机械工业出版社, 2014(10):273-279.
- [4] 张涛, 齐永奇. MATLAB 图像处理编程与应用[M]. 北京: 机械工业出版社, 2014(4):295-296.
- [5] 廖晓姣, 李英. 基于边缘检测和形态学的车牌定位算法[J]. 现代电子技术, 2011, 34(10):17-19.
- [6] 杨俊, 戚飞虎. A License Plate Locating Approach Based on Shape and Texture Characteristics%一种基于形状和纹理特征的车牌定位方法[J]. 计算机工

程, 2006, 032(002):170-171, 202.

[7]Ren Shaoqing, He Kaiming, Girshick Ross, Sun Jian. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. [J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(6).

[8]孙东卫, 朱程辉. 基于 Radon 变换的倾斜车牌图像角度检测与校正%Skew Angle Detection of the Vehicle License Plate Image and Correct Based on Radon Transformation[J]. 微计算机应用, 2008, 29(2):18-21.

[9]王莉影, 高心丹. 基于迁移学习的遥感影像树种类型分类[J]. 实验室研究与探索, 2019, 38(09):29-33+78.